

NBA Data WareHouse

Bases de Datos Avanzadas

Escuela Superior Informática (UCLM)

Mario Pérez Sánchez-Montañez, David Camuñas Sánchez

18 de febrero de 2020

Resumen

Introducción

Un almacén de datos o *Data Warehouse* es el instrumento que las organizaciones encontraron centralizar toda la información relevante, el objetivo de tomar decisiones informadas con más facilidad. Es decir, facilitar el almacenaje y análisis de los datos de la empresa.

En nuestro caso, hemos construido un almacén de datos para almacenar las estadísticas mas relevantes de la temporada 2018-2019 de la competición de baloncesto más popular, la NBA [2]. El trabajo consiste en la extracción de datos de la competición disponibles en [7] y almacenaje de estos datos en una base datos relacional para su posterior estudio.

Para el análisis y la extracción de datos, se llevará a cabo el proyecto con *Python* [11] y como motor de base de datos se utilizará *SQLite* [12]. Nuestra base de datos estará formada por cuatro tablas, que se describirán posteriormente.

Obtención de los datos

Los datos se han obtenido aplicando técnicas de *web scraping* [3] gracias a la librería *Beautiful Soup* [10] de *Python*. Con esta librería se obtiene el código HTML de una pagina web y se pueden realizar diversas operaciones con esa información, en nuestro caso hemos construido un *dataframe* [5] para poder construir posteriormente la base de datos.

0.1. Datos de jugadores

Los datos relacionados con los jugadores se han obtenido gracias al siguiente código [6] en *Python*:

```
from urllib.request import urlopen
from bs4 import BeautifulSoup
import pandas as pd

def get_player_stats(year):
    # URL page we will scraping (see image above)
    url = "https://www.basketball-reference.com/ \
    leagues/NBA_{}_totals.html".format(year)
    # this is the HTML from the given URL
    html = urlopen(url)
    soup = BeautifulSoup(html, features="html.parser")

    # use findALL() to get the column headers
    soup.findAll('tr', limit=2)
    # use getText() to extract the text we need into a list
    headers = [th.getText() for th in
                soup.findAll('tr', limit=2)[0].findAll('th')]
    # exclude the first column as we will not need the
    # ranking order from Basketball Reference for the analysis
    headers = headers[1:]

    # avoid the first header row
    rows = soup.findAll('tr')[1:]

    player_stats = [[td.getText() for td
                      in rows[i].findAll('td')]
                     for i in range(len(rows))]

    # Create DataFrame
    return pd.DataFrame(player_stats, columns=headers)

def get_rookie_stats(year):
    # URL page we will scraping (see image above)
    url = "https://www.basketball-reference.com/ \
    leagues/NBA_{}_rookies-season-stats.html".format(year)
    # this is the HTML from the given URL
    html = urlopen(url)
    soup = BeautifulSoup(html, features="html.parser")

    # use findALL() to get the column headers
    soup.findAll('tr', limit=2)
```

```

# use getText() to extract the text we need into a list
headers = [th.getText() for th in
soup.findAll('tr', limit=2)[1].findAll('th')]
# the first row is not the header
# exclude the first column as we will not need the
# ranking order from Basketball Reference for the analysis
headers = headers[1:]

# avoid the first header row
rows = soup.findAll('tr')[1:]

rookie_stats = [[td.getText() for td
in rows[i].findAll('td')]
for i in range(len(rows))]

return pd.DataFrame(rookie_stats, columns=headers)

```

Como se puede ver, el programa esta formado por dos funciones. La primera para obtener las estadísticas globales de todos los jugadores [9] y con la segundo se obtienen los datos relativos a los *rookies* (jugadores nóveles) [8]. Ambas funciones devolverán un objeto *dataframe* [5], porque en el programa principal se llamará a estas funciones para construir la base de datos, como se ha comentado anteriormente. Para el tratamiento de los datos en forma de *dataframe* utilizaremos la librería *pandas* [4].

Para obtener los datos que nos interesan de la web es necesario que sepamos cuáles son las etiquetas HTML que debemos de obtener del objeto *soup*. Esto normalmente se realiza inspeccionando la página web con cualquier navegador.

0.2. Datos de equipos

Los datos relativos a los equipos de la *nba* se han obtenido de forma similar a los datos de los jugadores:

```

from urllib.request import urlopen
from bs4 import BeautifulSoup
import pandas as pd

def get_team_stats(year):
    # URL page we will scraping (see image above)
    url = "https://www.basketball-reference.com/ \
leagues/NBA_{}_ratings.html".format(year)
    # this is the HTML from the given URL
    html = urlopen(url)
    soup = BeautifulSoup(html, features="html.parser")

    # use findALL() to get the column headers

```

```

soup.findAll('tr', limit=2)
# use getText() to extract the text we need into a list
headers = [th.getText() for th in
            soup.findAll('tr', limit=2)[1].findAll('th')]
# the first row is not the header
# exclude the first column as we will not need the ranking
# order from Basketball Reference for the analysis
headers = headers[1:]

# avoid the first header row
rows = soup.findAll('tr')[1:]

team_stats = [[td.getText() for td in rows[i].findAll('td')]
              for i in range(len(rows))]

team_df = pd.DataFrame(team_stats, columns=headers)

return team_df.sort_values('Team')

def get_entire_team_name():
    # URL page we will scraping (see image above)
    url = "https://en.wikipedia.org/wiki/ \
Wikipedia:WikiProject_National_Basketball_Association/ \
National_Basketball_Association_team_abbreviations "
    # this is the HTML from the given URL
    html = urlopen(url)
    soup = BeautifulSoup(html, features="html.parser")

    # avoid the first header row
    rows = soup.findAll('tr')[1:]

    team_names = [[td.getText().replace('\n', ' ') for
                  td in rows[i].findAll('td')]
                  for i in range(len(rows))]

    team_names_df = pd.DataFrame(team_names,
                                columns=['Key', 'Name'])
    return team_names_df.sort_values('Name')

```

La función para obtener los datos de los equipos es muy similar a las funciones mencionadas anteriormente, con la diferencia que el *dataframe* que retornamos lo ordenamos por el nombre del equipo. La segunda función en un principio no la desarrollamos, pero en la construcción de la base de datos apreciamos que los datos de los jugadores indican el equipo mediante abreviaturas. Por lo tanto esta función la utilizaremos para establecer las equivalencias.

Creación de la base de datos

La creación de la base de datos la hemos automatizado gracias al siguiente *script* que llama a las funciones explicadas en la sección anterior ??:

```
from team_stats import *
from player_stats import *
import pandas as pd
import sqlite3 as sqlite
import os

players_df, teams_df = None, None
rookies_df, central_df = None, None

def load_data():
    global players_df, teams_df, rookies_df
    # Players DataFrame
    players_df = get_player_stats(2019).reset_index()
    players_df = players_df.rename(columns={'index': 'id'})

    # Teams Abbreviation DataFrame
    teams_abbreviation_df = get_entire_team_name()
    teams_abbreviation_df.at[23, 'Key'] = 'PHO'
    teams_abbreviation_df.at[1, 'Key'] = 'BOS'
    teams_abbreviation_df.at[2, 'Key'] = 'BRK'
    teams_abbreviation_df.at[3, 'Key'] = 'CHO'

    # Teams DataFrame
    teams_df = get_team_stats(2019).reset_index()
    teams_df = teams_df.rename(columns={'index': 'id'})
    teams_df.insert(1, "Key", teams_abbreviation_df['Key'], False)

    # Rookie DataFrame
    rookies_df = get_rookie_stats(2019).reset_index()
    rookies_df = rookies_df.rename(columns={'index': 'id'})

def clean_data():
    global players_df, teams_df, rookies_df
    # Remove columns that we don't use
    players_df = players_df.drop('eFG%', 1)
    teams_df = teams_df.drop(
        ['Div', 'MOV/A', 'ORtg/A', 'DRtg/A', 'NRtg/A'], 1)
    rookies_df = rookies_df.drop(
        ['Yrs', 'MP', 'PTS', 'TRB', 'AST'], 1)

    # Remove NaN rows
```

```

players_df = players_df.dropna()
teams_df = teams_df.dropna()
rookies_df = rookies_df.dropna()

# Remove players with invalid team
for i, row in players_df.iterrows():
    if row['Tm'] == 'TOT':
        continue

    if row['Tm'] not in list(teams_df['Key']):
        players_df = players_df.drop(index=i)

# Reboot index, because it need start with 0
rookies_df = rookies_df.reset_index().drop('index', 1)

def build_central_df():
    global players_df, teams_df, rookies_df, central_df
    central_df = pd.DataFrame(
        columns=['id_player', 'id_team',
                'Player', 'Team', 'Rookie'])

    # build id_player
    central_df['id_player'] = players_df['id']
    # build player names
    central_df['Player'] = players_df['Player']

    for i, row in central_df.iterrows():
        # build id team
        if players_df.loc[i]['Tm'] == 'TOT':
            # id for total statistics, because he
            # played in more one team
            row['id_team'] = -1
        else:
            row['id_team'] = int(teams_df.loc[list(
                teams_df['Key']).index(
                    players_df.loc[i]['Tm'])]['id'])

        # build team name
        if row['id_team'] == -1:
            row['Team'] = 'Total'
        else:
            row['Team'] = teams_df.loc[list(
                teams_df['id']).index(row['id_team'])]['Team']

        # build is rookie
        if row['Player'] in list(rookies_df['Player']):

```

```

        row['Rookie'] = int(rookies_df.loc[list(
            rookies_df['Player']).index(row['Player'])]['id'])

        central_df.loc[i] = row

# Remove team column, because team info will be in the central
players_df = players_df.drop('Tm', 1)

def build_database():
    global players_df, teams_df, rookies_df, central_df

    sql_data = 'nba_data.db'
    connection = sqlite.connect(sql_data)

    # load db creation script
    file = open('creation.sql', 'r')
    query = ''
    for line in file:
        query += line

    # db tables creation
    connection.cursor().executescript(query)

    # Load players_df in db
    players_df.to_sql('PLAYERS', connection,
        if_exists='append', index=False)

    # Load teams_df in db
    teams_df.to_sql('TEAMS', connection,
        if_exists='append', index=False)

    # Load rookies_df in db
    rookies_df.to_sql('ROOKIES', connection,
        if_exists='append', index=False)

    # Load central_df in db
    central_df.to_sql('PLAYER_TEAM', connection,
        if_exists='append', index=False)

    # Close the connection with the db
    connection.close()

if __name__ == '__main__':
    if os.path.isfile('nba_data.db'):
        print('The db file exists, remove to build newly')
    else:
        load_data()

```

```
clean_data()  
build_central_df()  
build_database()
```

El programa lleva a cabo las siguientes operaciones:

- **Cargar los datos:** se llama a las funciones explicadas anteriormente para cargar la información relativas a jugadores, *rookies* y equipos. Además, en esta parte del programa también se establece la equivalencia de los equipos con sus abreviaturas.
- **Transformación de datos:** se realiza una limpieza de los datos, que consiste en eliminar las columnas que no vamos a utilizar, eliminar las filas vacías y eliminación de jugadores que no juegan en un equipo de la nba.
- **Construcción del *dataframe* central:** estos datos se usarán para construir una tabla central que relacione los datos de jugadores, *rookies* y equipos, siguiendo el modelo de estrella [1].
- **Construcción de la base datos:** en este último paso se construirán las cuatro tablas de la base datos y se introducirán los datos guardados en los cuatro *dataframes* que hemos comentado. Las operaciones que se ejecutan para crear las tabla y sus respectivas relaciones se pueden ver en el fichero *creation.sql*.

Referencias

1. https://es.wikipedia.org/wiki/Esquema_en_estrella. Esquema en estrella.
2. https://es.wikipedia.org/wiki/National_Basketball_Association. National basketball association.
3. https://es.wikipedia.org/wiki/Web_scraping. Web scraping.
4. <https://pandas.pydata.org/>. Pandas.
5. <https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.DataFrame.html>. Pandas dataframe.
6. <https://towardsdatascience.com/web-scraping-nba-stats-4b4f8c525994>. Web scraping nba stats.
7. <https://www.basketball-reference.com>. Basketball reference.
8. https://www.basketball-reference.com/leagues/NBA_2019_rookies-season-stats.html. Rookies stats.
9. https://www.basketball-reference.com/leagues/NBA_2019_totals.html. Player stats.
10. <https://www.crummy.com/software/BeautifulSoup/bs4/doc/>. Beautiful soup.

11. <https://www.python.org/>. Python software foundation.
12. <https://www.sqlite.org/index.html>. Sqlite.